



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی ارشد
گرایش هوش مصنوعی و رباتیکز

بهبود سرعت مدل های پخشی

نگارش

عطیه غفارلوی مقدم

استاد راهنما

دکتر احمد نیک آبادی

دی ماه ۱۴۰۳

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

به نام خدا

تعهدنامه اصالت اثر

تاریخ: دی ماه ۱۴۰۳

اینجانب عطیه غفارلوی مقدم متعهد می‌شوم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب تحت نظارت و راهنمایی اساتید دانشگاه صنعتی امیرکبیر بوده و به دستاوردهای دیگران که در این پژوهش از آنها استفاده شده است مطابق مقررات و روال متعارف ارجاع و در فهرست منابع و مآخذ ذکر گردیده است. این پایان‌نامه قبلاً برای احراز هیچ مدرک هم‌سطح یا بالاتر ارائه نگردیده است. در صورت اثبات تخلف در هر زمان، مدرک تحصیلی صادر شده توسط دانشگاه از درجه اعتبار ساقط بوده و دانشگاه حق پیگیری قانونی خواهد داشت.

کلیه نتایج و حقوق حاصل از این پایان‌نامه متعلق به دانشگاه صنعتی امیرکبیر می‌باشد. هرگونه استفاده از نتایج علمی و عملی، واگذاری اطلاعات به دیگران یا چاپ و تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان‌نامه بدون موافقت کتبی دانشگاه صنعتی امیرکبیر ممنوع است. نقل مطالب با ذکر مآخذ بلامانع است.

عطیه غفارلوی مقدم

امضا

چکیده

مدل‌های پخشی به عنوان یک خانواده‌ی قدرتمند از مدل‌های مولد با نتایج قابل توجه در حوزه‌های مختلف تصویر، صوت، متن و گراف، در سال‌های اخیر مورد توجه بسیاری از محققین یادگیری ماشین قرار گرفته‌اند. همه‌ی مدل‌های مطرح شده در این خانواده از یک رویکرد مشابه پیروی می‌کنند و آن هم تخریب داده با نویز در یک فرآیند گام به گام و سپس بازگرداندن این فرآیند برای تولید نمونه‌های جدید از داده می‌باشد. در این گزارش ابتدا به بررسی دقیق سه دسته‌ی مطرح مدل‌های پخشی و شباهت‌ها و تفاوت‌های آنها می‌پردازیم. پس از معرفی این مدل‌ها، به بررسی رابطه‌ی میان آنها و انواعی دیگر از مدل‌های مولد می‌پردازیم و در نهایت به تعدادی از چالش‌های مطرح در خصوص این مدل‌ها اشاره می‌کنیم.

واژه‌های کلیدی:

مدل‌های مولد، مدل‌های پخشی، مدل‌های مولد مبتنی بر امتیاز، مدل‌های پخشی نویززدای احتمالاتی

فهرست مطالب

صفحه

عنوان

۱		۱ مقدمه
۲		۲ مدل‌های پخشی و رویکردهای افزایش سرعت
۳		۱-۲ تعاریف
۳		۱-۱-۲ مدل‌های مولد
۳		۲-۱-۲ مدل‌های پخشی
۵		۳-۱-۲ مدل‌های پخشی احتمالاتی نویزدا
۱۰		۴-۱-۲ انواع معماری مدل‌های پخشی نویزدا
۱۴		۲-۲ رویکردهای افزایش سرعت
۱۶		۱-۲-۲ رویکردهای کاهش تعداد گام‌ها
۱۷		۲-۲-۲ رویکردهای کاهش محاسبات هر گام

شکل	فهرست تصاویر	صفحه
۱-۲	روند کلی یک مدل پخشی	۴
۲-۲	فرآیند پخش در مپناها	۵
۳-۲	معماری $++ pixelCNN$	۱۱
۴-۲	معماری شبکه‌ی یو	۱۲
۵-۲	معماری مدل‌های پخشی پنهان	۱۳
۶-۲	معماری مدل‌های مبتنی بر مبدل	۱۴
۷-۲	مشکل سه‌گانه‌ی مدل‌های مولد	۱۶

صفحه

فهرست جداول

جدول

فهرست اختصارات

عنوان اختصاری عنوان کامل

مپنا مدل پخشی نويززدای احتمالاتی

فصل اول

مقدمه

فصل دوم

مدل‌های پخشی و رویکردهای افزایش سرعت

۱-۲ تعاریف

۱-۱-۲ مدل‌های مولد

مدل‌های مولد عمیق دسته‌ای از مدل‌های پرکاربرد و جدید در حوزه‌ی هوش مصنوعی هستند که تلاش می‌کنند تا توزیع اصلی داده‌ی نمونه‌برداری شده را مدل کنند و با استفاده از این توزیع انواع مختلفی از سوالات در خصوص داده و دسته‌های آن را پاسخ دهند. در واقع اصلی‌ترین هدف یک مدل مولد، استفاده از مشاهدات شبیه‌سازی شده یا نمونه برداری شده از یک توزیع برای تخمین آن توزیع و سپس تولید نمونه‌های جدید از توزیع تخمین زده شده می‌باشد. مدل‌های مولد کاربردهای متنوعی در یادگیری ماشین دارند، از جمله‌ی این کاربردها می‌توان به تولید عکس‌های باکیفیت، تولید قطعه‌های موسیقی و یا صوت، افزایش کارایی یادگیری نیمه نظارتی^۱، تشخیص ناهنجاری^۲، یادگیری تقلیدی و کمک به یادگیری تقویتی اشاره کرد. پیشرفت‌های اخیر این حوزه دو رویکرد کلی را دنبال می‌کنند: رویکردهای مبتنی بر درست‌نمایی^۳ و شبکه‌های مولد تقابلی^۴. در رویکردهای مبتنی بر درست‌نمایی از لگاریتم درست‌نمایی یا خطاهای جایگزین به عنوان تابع هدف یادگیری استفاده می‌شود؛ در حالیکه در شبکه‌های مولد تقابلی تلاش می‌شود تا یادگیری با یک رویکرد تقابلی بین دو شبکه‌ی تمایزگر^۵ و تولیدکننده^۶ صورت گیرد. با وجود عملکرد قابل توجه مدل‌های مبتنی بر درست‌نمایی و شبکه‌های مولد تقابلی، این مدل‌ها به واسطه‌ی نوع تعریفشان درگیر برخی محدودیت‌های ذاتی هستند. به عنوان مثال مدل‌های مبتنی بر درست‌نمایی برای ساخت توزیع‌های نرمال شده نیازمند به کارگیری معماری‌های خاص یا استفاده از توابع خطای جایگزین (مانند حد پایین مشاهده^۷ در خودکدگذارهای تغییراتی^۸) در فرآیند یادگیری هستند. شبکه‌های مولد تقابلی مشکلات موجود در مدل‌های مبتنی بر درست‌نمایی را ندارند اما فرآیند یادگیری آنها به خاطر ماهیت تقابلی آن می‌تواند دچار ناپایداری شود. همچنین تابع هدف مدل‌های مولد تقابلی برای مقایسه و ارزیابی انواع این مدل‌ها چندان مناسب نیست [۱۴].

۲-۱-۲ مدل‌های پخشی

مدل‌های پخشی^۹ یک دسته‌ی نوظهور از مدل‌های مولد هستند که با توجه به عملکرد مناسب آنها در حوزه‌های تصویر، صوت، متن و گراف به سرعت مورد استقبال قرار گرفتند. وجه مشترک همه‌ی مدل‌های

^۱Semi-supervised learning

^۲Anomaly

^۳Likelihood

^۴Generative adversarial networks

^۵Discriminator

^۶Generator

^۷Evidence lower bound

^۸Variational autoencoders

^۹Diffusion models

پخشی این است که در یک فرآیند رو به جلو^{۱۰} داده را با نویز تخریب می‌کنند و در نتیجه از توزیع داده به یک توزیع دلخواه قابل محاسبه می‌رسند و سپس در یک مسیر رو به عقب که توسط مدل یاد گرفته می‌شود، تلاش می‌کنند تا داده را بازسازی و از یک نمونه از توزیع دلخواه به یک نمونه از توزیع داده‌ها برسند. این موضوع در شکل ۱-۲ نشان داده شده است.



شکل ۱-۲: روند کلی یک مدل پخشی

در هر مدل پخشی یک فرآیند ثابت گام به گام رو به جلو برای تخریب داده و یک فرآیند معکوس برای تولید یک نمونه داده از نویز وجود دارد [۴].

با وجود اینکه چهارچوب گفته شده در بند قبل در همه‌ی مدل‌های پخشی وجود دارد؛ رویکردهای مختلفی برای فرموله سازی و پیاده سازی این روش وجود دارد. در مدل‌های مولد مبتنی بر تابع امتیاز^{۱۱} تلاش می‌شود با استفاده از گرادیان لگاریتم توزیع داده، که به آن تابع امتیاز^{۱۲} می‌گوییم، و یک فرآیند گام به گام حرکت در جهت این گرادیان نمونه‌ی جدید تولید کنیم. از طرفی در مدل‌های پخشی نویززدای احتمالاتی فرآیند تخریب داده و تولید نمونه با یک زنجیره‌ی مارکوفی احتمالاتی مدل می‌شود و در نهایت در مدل‌های پخشی مبتنی بر معادلات دیفرانسیل تصادفی، فرآیند تخریب به صورت یک معادله دیفرانسیل تصادفی پیوسته مدل می‌شود که با پیدا کردن معکوس این معادله و گسسته سازی آن امکان تولید نمونه‌ی جدید از توزیع داده‌ها فراهم می‌گردد.

می‌توان نشان داد که مدل‌های پخشی بسیاری از محدودیت‌های مدل‌های مولد دیگر مانند نیاز به تمایزگر در شبکه‌های مولد تقابلی، نیاز به مقیدسازی شبکه در جریان‌های نرمال‌ساز^{۱۳} و نیاز به تنظیم توزیع‌های پسین در خودکدگذارهای تغییراتی را ندارند و قابلیت تولید تصاویر باکیفیت و متنوع را دارند. مشکل اصلی در مدل‌های پخشی فرآیند نمونه‌برداری طولانی آنهاست که باعث عدم کارایی این مدل‌ها در کاربردهای تعاملی می‌شود. با رفع این موضوع می‌توان اطمینان حاصل کرد که این دسته از مدل‌های مولد از توانایی همه‌جانبه‌ای برای به کارگیری در حوزه‌های مختلف برخوردار هستند.

¹⁰Forward process

¹¹Score-based generative models


¹²Score function

¹³Normalizing flows

۳-۱-۲ مدل‌های پخش احتمالاتی نويززدا

۱-۳-۱-۲ تعريف مدل

مدل‌های پخش نويززداي احتمالاتي^{۱۴} يا به اختصار مپناها مدل‌هایی مبتنی بر متغیر پنهان^{۱۵} هستند که از یک زنجیره‌ی مارکوفی^{۱۶} برای فرآیند پخش استفاده می‌کنند. رویکرد کلی این مدل‌ها به این صورت است که در یک مسیر رو به جلو هر توزیع پیچیده‌ای از داده‌ها را می‌گیرد و آن را به یک توزیع اولیه که ساده و قابل محاسبه است تبدیل می‌کند و سپس یک مسیر روبه عقب محدود به زمان را یاد می‌گیرد که نمونه‌هایی از توزیع اولیه را به نمونه‌های توزیع داده تبدیل کند و این همان ایده‌ی کلی مدل مولد پخش می‌باشد. تصویر ۲-۲ این فرآیند را نشان می‌دهد. بنابراین این مدل سه مشخصه‌ی اصلی دارد: مسیر رو به جلو، مسیر رو به عقب و تابع مدل مولد که در ادامه هر یک را توضیح می‌دهیم.



شکل ۲-۲: فرآیند پخش در مپناها

مدل گراف‌ی جهت‌دار یک مپنا که به صورت یک زنجیره‌ی مارکوف روبه جلو و معکوس آن می‌باشد^[۳].

۲-۳-۱-۲ مسیر رو به جلو

اگر توزیع داده را با $q(x^{(0)})$ نشان دهیم، این توزیع به صورت مرحله به مرحله به یک توزیع $\pi(y)$ که از نظر آنالیزی قابل بیان است تبدیل می‌شود و این تبدیل توسط یک هسته‌ی $T_\pi(y|y'; \beta)$ صورت می‌گیرد که β را نرخ پخش^{۱۷} می‌گوییم و داریم:

$$\pi(y) = \int dy' T_\pi(y|y'; \beta) \pi(y') \quad (۱-۲)$$

¹⁴Denoising diffusion probabilistic models(DDPMs)

¹⁵Latent variable models

¹⁶Markov Chain

¹⁷Diffusion rate

$$q(x^{(t)}|x^{(t-1)}) = T_{\pi}(x^{(t)}|x^{(t-1)}; \beta_t) \quad (2-2)$$

و بنابراین مسیر رو به جلو^{۱۸} با شروع از توزیع داده‌ها و طی T گام پخشی به صورت زیر است:

$$q(x^{(0...T)}) = q(x^{(0)}) \prod_{t=1}^T q(x^{(t)}|x^{(t-1)}) \quad (3-2)$$

در ادامه‌ی این فصل هسته‌ی $q(x^{(t)}|x^{(t-1)})$ هسته‌ی گاوسی در نظر گرفته می‌شود اما هسته‌های دیگری چون هسته‌ی دوجمله‌ای^{۱۹} نیز وجود دارند. یک ویژگی حائز اهمیت مسیر رو به جلو این است که می‌توان به جای استفاده از فرم زنجیره‌ی مارکوفی آن از یک فرم بسته استفاده کرد به این معنا که برای یافتن $x^{(t)}$ در زمان دلخواه t می‌توان از رابطه‌ی زیر کمک گرفت:

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I) \quad (4-2)$$

که $\alpha_t := 1 - \beta_t$ و $\bar{\alpha}_t := \prod_{s=1}^t \alpha_s$ تعریف می‌شود.

۳-۳-۱-۲ مسیر رو به عقب

برای یادگیری توزیع مولد نیاز است که بتوانیم برعکس مسیر رو به جلو را یاد بگیریم و این به این معناست که باید بتوانیم از یک توزیع دلخواه قابل محاسبه به توزیع داده برسیم. بنابراین با تعریف توزیع اولیه به صورت $p(x^{(T)}) = \pi(x^{(T)})$ داریم:

$$p(x^{(0...T)}) = p(x^{(T)}) \prod_{t=1}^T p(x^{(t-1)}|x^{(t)}) \quad (5-2)$$

می‌توان نشان داد که اگر فرآیند پخش گاوسی باشد و گام‌های پخش β خیلی کوچک باشند آنگاه معکوس فرآیند پخش نیز گاوسی می‌باشد^[۱]. و بنابراین هر چقدر که طول این زنجیره بیشتر باشد β کوچکتر می‌شود و می‌توان از تابع گاوسی برای مسیر معکوس نیز کمک گرفت. در فرآیند یادگیری با توجه به

¹⁸Forward trajectory

¹⁹Binomial kernel

اینکه هسته‌ی گذر^{۲۰} زنجیره‌ی مارکوفی یک تابع گاوسی است، برای ساخت زنجیره تنها نیاز به میانگین و کوواریانس این تابع گاوسی داریم و در ادامه سعی می‌کنیم آنها را تخمین بزنیم.

۴-۳-۱-۲ تابع مدل مولد

تابع احتمال تولید شده توسط مپنا به صورت زیر می‌باشد:

$$p(x^{(0)}) = \int dx^{(1...T)} p(x^{(0...T)}) \quad (۶-۲)$$

از آنجاییکه انتگرال در حالت کلی غیرقابل محاسبه^{۲۱} است، می‌توان با ایده گرفتن از نمونه برداری اهمیت^{۲۲} به جای محاسبه‌ی انتگرال از میانگین احتمال نسبی مسیر رو به جلو و مسیر رو به عقب استفاده کرد که به صورت زیر قابل بیان است:

$$p(x^{(0)}) = \int dx^{(1...T)} q(x^{(1...T)}|x^{(0)}) \prod_{t=1}^T \frac{p(x^{(t-1)}|x^{(t)})}{q(x^{(t)}|x^{(t-1)})} \quad (۷-۲)$$

۵-۳-۱-۲ تعریف تابع خطا

با توجه به مدل تعریف شده در قسمت قبل، آموزش شبکه معادل بیشینه کردن لگاریتم درست‌نمایی^{۲۳} تابع مدل مولد و یا کمینه کردن منفی این تابع است. بنابراین تابع هزینه را می‌توان به صورت زیر نوشت:

$$L = \int dx^{(0)} q(x^{(0)}) \log p(x^{(0)}) \quad (۸-۲)$$

در اینجا برای آموزش به جای بهینه سازی مستقیم لگاریتم درست‌نمایی از بهینه سازی حد تغییراتی^{۲۴} آن کمک می‌گیریم که به صورت زیر قابل تعریف است:

$$\mathbb{E}[-\log p_{\theta}(x^0)] \leq \mathbb{E}_q[-\log \frac{p_{\theta}(x^{0:T})}{q(x^{1:T}|x^0)}] = \mathbb{E}_q[-\log p(x^T) - \sum_{t \geq 1} \log \frac{p_{\theta}(x^{t-1}|x^t)}{q(x^t|x^{t-1})}] =: L \quad (۹-۲)$$

²⁰Transition kernel

²¹Intractable

²²Importance sampling

²³Log-likelihood

²⁴Variational bound

۲-۱-۳ تغییر پارامتر تابع خطا

از آنجایی که ترکیب مسیر رو به جلو و مسیر معکوس شبیه به یک کدگذار تغییراتی است، می‌توان تابع هزینه را به صورت زیر بازنویسی کرد:

$$\mathcal{L}_{vib} = \mathcal{L}_0 + \mathcal{L}_1 + \dots + \mathcal{L}_{T-1} + \mathcal{L}_T \quad (10-2)$$

$$\mathcal{L}_0 = -\log p_\theta(x_0|x_1) \quad (11-2)$$

$$\mathcal{L}_{t-1} = \mathcal{D}_{KL}(q(x_{t-1}|x_t, x_0) \| p_\theta(x_{t-1}|x_t)) \quad (12-2)$$

$$\mathcal{L}_T = \mathcal{D}_{KL}(q(x_T|x_0) \| p(x_T)) \quad (13-2)$$

و از آنجایی که در صورت کوچک بودن β_t هر دوی $q(x_{t-1}|x_t, x_0)$ و $p_\theta(x_{t-1}|x_t)$ توزیع‌هایی گاوسی هستند در نتیجه دیورجنس KL^{25} آنها را می‌توان به فرم تفاضل میانگین آنها در نظر گرفت و در نتیجه برای معادله ی (۱۲-۲) داریم:

$$\mathcal{L}_{t-1} = \mathbb{E}_q \left[\frac{1}{2\sigma_t^2} \|\tilde{\mu}_t(x_t, x_0) - \mu_\theta(x_t, t)\|^2 \right] + C \quad (14-2)$$

که در واقع نشان می‌دهد که در فرآیند آموزش یک مدل پخشی بهینه سازی خطا شامل تخمین میانگین پسین^{۲۶} فرآیند رو به جلو می‌باشد. لازم است اشاره کنیم که در مقاله‌ی اصلی مقدار واریانس ثابت در نظر گرفته شده است. از طرفی با تغییر پارامتر $x_t(x_0, \epsilon) = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{(1 - \bar{\alpha}_t)}\epsilon$ برای $\epsilon \sim \mathcal{N}(0, I)$ و قراردادی آن در فرمول معادله‌ی (۱۴-۲) می‌توان نشان داد که تخمین $\mu_\theta(x_t, t)$ به صورت زیر قابل پارامتری سازی است:

²⁵KL-divergence

²⁶Posterior mean

$$\mu_{\theta}(x_t, t) = \tilde{\mu}_t \left(x_t, \frac{1}{\sqrt{\bar{\alpha}_t}} (x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_{\theta}(x_t)) \right) = \frac{1}{\sqrt{\bar{\alpha}_t}} (x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(x_t, t)) \quad (15-2)$$

که ϵ_{θ} یک تخمین از نویز موجود در x_t می‌باشد و در نتیجه برای محاسبه ی یک نمونه ی x_{t-1} تنها کافیست که عبارت زیر را محاسبه کنیم:

$$x_{t-1} = \frac{1}{\sqrt{\bar{\alpha}_t}} (x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_{\theta}(x_t, t) + \sigma_t z) \quad (16-2)$$

که z از توزیع گاوسی با میانگین صفر و کوواریانس همانی می‌آید. این تغییر پارامتر نشان می‌دهد که برای آموزش یک فرآیند رو به عقب می‌توان از تخمین $\tilde{\mu}_t$ با تابع میانگین وابسته به زمان μ_{θ} استفاده کرد و یا مستقیماً نویز اضافه شده به داده را با تخمین ϵ محاسبه کرد.

۷-۳-۱-۲ فرآیند یادگیری

با توجه به تغییر پارامتر انجام شده در قسمت قبل و همچنین به کارگیری آن در معادله ی (۱۰-۲) می‌توان به تابع هزینه ای رسید که کاملاً نسبت به θ مشتق پذیر است و برای آموزش مناسب است اما برای سادگی پیاده سازی و افزایش کیفیت نمونه‌های تولیدی می‌توان تابع هزینه را به شکل زیر نیز بازنویسی کرد:

$$L_{simple}(\theta) = \mathbb{E}_{t, x_0, \epsilon} \left[\left\| \epsilon - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t) \right\|^2 \right] \quad (17-2)$$

که t از یک توزیع یونیفرم بین ۱ و T می‌آید و واریانس β_t در این فرآیند یک پارامتر ثابت بدون یادگیری می‌باشد. الگوریتم ۱ فرآیند آموزش یک مپنا را نشان می‌دهد.

الگوریتم ۱ آموزش

۱: مراحل زیر را تکرار کن

۲: $\mathbf{x}_0 \sim q(\mathbf{x}_0)$

۳: $t \sim \text{Uniform}(\{1, \dots, T\})$

۴: $\epsilon \sim \mathcal{N}(0, \mathbf{I})$

۵: گام نزول در جهت گرادیان را روی تابع زیر اعمال کن

$$\nabla_{\theta} \|\epsilon - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t)\|^2$$

۶: تا زمانی که همگرا شود

۲-۱-۳-۸ فرآیند تولید نمونه‌ی جدید

همانطور که در الگوریتم ۲ نشان داده شده است؛ برای نمونه برداری ابتدا یک نمونه از توزیع $\mathcal{N}(0, \mathbf{I})$ تولید می‌کنیم سپس به صورت معکوس هر بار نمونه را به شبکه می‌دهیم و نمونه‌ی نویززدایی شده را دریافت می‌کنیم. این فرآیند تا جایی ادامه پیدا می‌کند که به یک نمونه از توزیع $q(\mathbf{x}_0)$ برسیم.

الگوریتم ۲ نمونه‌برداری

۱: $\mathbf{x}_T \sim \mathcal{N}(0, \mathbf{I})$

۲: برای $t = T, \dots, 1$ مراحل زیر را انجام بده:

۳: $\mathbf{z} \sim \mathcal{N}(0, \mathbf{I})$ اگر $t > 1$ ، در غیر این صورت $\mathbf{z} = 0$

۴: $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1-\alpha_t}{\sqrt{1-\alpha_t}} \epsilon_{\theta}(\mathbf{x}_t, t) \right) + \sigma_t \mathbf{z}$


۵: پایان حلقه

۶: مقدار $\mathbf{x}_0$ را برگردان.

در بخش بعدی سراغ انواع معماری‌ها و پیاده‌سازی‌های مپناها می‌رویم.

۲-۱-۴ انواع معماری مدل‌های پخشی نویززدای احتمالاتی

در ساختار مپناها از هسته‌ی اصلی `pixelCNN++` [۱۱] استفاده شده است که در واقع نوعی شبکه‌ی یو با اتصالات گسترده‌ی باقی‌مانده‌ای می‌باشد. شکل ۲-۳ ساختار کلی شبکه‌ی به کار گرفته شده را نشان می‌دهد.



شکل ۲-۳: معماری $pixelCNN++$

شبکه‌ی $pixelCNN++$ که نوعی شبکه‌ی یو با اتصالات باقی‌مانده‌ای گسترده است به عنوان شبکه‌ی اصلی در مپ‌ها استفاده می‌شود [۱۱].

تا قبل از ارائه‌ی مدل پخشی نهان [۹]^{۲۷} عمده‌ی ساختار ارائه شده برای مپ‌ها به تنهایی بر پایه‌ی شبکه‌ی یو [۱۰] یا یکی از انواع این شبکه بود. شبکه‌ی یو یک ساختار کدگذار-کدگشا^{۲۸} است که ابتدا برای مسالهی قطعه‌بندی تصاویر پزشکی ارائه شد. ویژگی خاص این شبکه نسبت به سایر ساختارهای کدگذار-کدگشا وجود اتصالات پرشی^{۲۹} می‌باشد. این اتصالات با هدف ترکیب اطلاعات سطح بالا و اطلاعات محلی و نیز افزایش رزولوشن تصویر خروجی استفاده شدند. شکل ۲-۴ ساختار یک شبکه‌ی یو را نشان می‌دهد.

۲-۴-۱-۲ مدل پخشی نهان

استفاده از شبکه‌ی یو به تنهایی، چالش‌های زیاد دارد؛ از جمله‌ی این مشکلات می‌توان به هزینه‌ی محاسباتی و سنگین بودن شبکه‌ی یو اشاره کرد که این موضوع با افزایش رزولوشن تصویر می‌تواند هزینه‌ی زیادی را ایجاد کند. از طرفی در اکثر مپ‌ها فرآیند آموزش و نمونه‌برداری شبکه‌ی یو در فضای پیکسلی انجام می‌شود که ما را نیازمند تعریف یک شبکه‌ی متناظر به ازای هر رزولوشن و یا تغییر ابعاد تصویر می‌کند. علاوه بر موارد ذکر شده در شبکه‌های یو به کار گرفته شده در فرآیند مپ‌ها امکان شرطی‌سازی انعطاف پذیر وجود ندارد. این شبکه امکان انجام شرطی‌سازی بر اساس نام کلاس‌ها یا نویز ابتدایی تصویر را دارد ولی امکان دریافت متن و یا نقشه‌ی معنایی^{۳۰} و پردازش آنها به عنوان شرط را بدون بهینه‌سازی در معماری ندارد.


مدل‌های پخشی نهان با تمرکز بر رفع نقاط ضعف اشاره شده در مدل‌های شبکه‌ی یو ابتدایی ارائه شدند. این مدل‌ها تلاش می‌کنند که اولاً با انتقال تصویر از فضای پیکسلی به فضای پنهان با ابعاد کمتر از حجم

²⁷Latent Diffusion model

²⁸Encoder-Decoder

²⁹Skip Connection

³⁰Semantic Map



شکل ۲-۴: معماری شبکه‌ی یو


معماری کلی شبکه‌ی یو که اولین بار برای مساله‌ی قطعه‌بندی معنایی تصاویر پزشکی ارائه شد و شامل سه بخش کدگذار، کدگشا و اتصالات پرشی است [۱۰].

محاسبات بکاهند. و ثانياً با اضافه کردن بلوک‌های توجه متقابل^{۳۱} انعطاف پذیری مدل را به واسطه‌ی امکان شرطی‌سازی بر روی هر شکلی از شرط شامل متن یا نقشه‌ی معنایی افزایش دهند. خروجی این تغییرات باعث تولید تصاویر با کیفیت بهتر و در رزولوشن‌های بالاتر می‌باشد.

شکل ۲-۶ معماری این مدل را نشان می‌دهد. این مدل با به کارگیری یک خودکدگذار تغییراتی از پیش آموزش داده شده، ابتدا تصویر را از فضای پیکسلی به فضای پنهان می‌برد. در فضای پنهان، فرآیند یادگیری و نمونه‌برداری مشابه هر مدل مپنای دیگری انجام می‌شود و معماری اصلی شبکه‌ی نويززدا نیز یک شبکه‌ی یو با اتصالات پرشی و بلوک‌های توجه متقابل است. این مدل با استفاده از بلوک‌های توجه متقابل شرط را روی فرآیند نويززدایی اعمال می‌کند و در نهایت این مدل پس از پایان مراحل نويز زدایی تصویر را از فضای پنهان به فضای پیکسلی باز می‌گرداند.

مدل‌های *Stable Diffusion* که در این پروژه به کار گرفته شده‌اند؛ از این معماری تبعیت می‌کنند. که در فصل‌های پیش رو در خصوص جزئیات پیاده‌سازی آنها بیشتر صحبت خواهیم کرد.

³¹Cross-Attention Blocks



شکل ۲-۵: معماری مدل‌های پخشی پنهان

در شکل بالا شبکه‌ی ϵ کدگذار خود کدگذار تغییراتی است که تصویر ورودی x را دریافت می‌کند و آن را به تصویر در فضای پنهان z تبدیل می‌کند. همچنین τ_θ یک کدگذار مختص دامنه‌ی مساله^{۳۲} است که برای تبدیل شرط به یک بازنمایی قابل درک توسط مدل به کار گرفته می‌شود. همچنین D نیز کدگشای خود کدگذار تغییراتی است که تصویر نویززدایی شده در فضای پنهان را به تصویر در فضای پیکسلی می‌برد^۹].

۲-۴-۱-۲ مدل پخشی مبتنی بر مبدل

در مدل‌های پخشی مبتنی بر مبدل^{۳۳} [۸] به جای استفاده از شبکه‌ی یو به عنوان شبکه‌ی نویززا از ساختار مبدل تصویری^{۳۴} استفاده می‌شود. انتخاب این مبدل‌ها به عنوان هسته‌ی اصلی مدل‌های پخشی از این جهت است که هم می‌توانند وابستگی‌های^{۳۵} قسمت‌های مختلف تصویر را مدل کنند و هم اینکه نسبت به شبکه‌ی یو ساختارهای مقیاس پذیرتری هستند. همچنین به کارگیری این مبدل‌ها در انواعی از دامنه‌ها مانند پردازش زبان طبیعی و سایر وظایف حوزه‌ی بینایی کارایی آنها را نسبت به سایر معماری‌ها نشان می‌دهد. و در نهایت وجود مکانیزم توجه به خود در مدل‌های مبدل باعث می‌شود که وابستگی‌های موجود در نواحی دور یا نزدیک تصویر به خوبی مدل می‌شوند.

این مدل، مشابه مدل پخشی پنهان در فضای پنهان حاصل از یک خودکدگذار تغییراتی نویززدایی می‌کند. این مدل به جای استفاده از یک شبکه‌ی نویززدایی مبتنی بر شبکه‌ی یو از یک ساختار مطابق شکل؟؟ استفاده می‌کند. در این حالت ابتدا تصویر ورودی به فضای پنهان برده می‌شود و در آنجا مدل تصویر پنهان را به تعدادی قطعه^{۳۶} تقسیم می‌کند که توسط مبدل پردازش می‌شوند. همچنین در این مدل


^{۳۳}Diffusion Transformer Models

^{۳۴}Vision Transformer

^{۳۵}Long-range Dependency

^{۳۶}Patch

از یک رویکرد به نام $adaLN - zero$ برای اضافه کردن نام کلاس و شرطی‌سازی استفاده می‌شود. این رویکرد برخلاف مدل‌های پخشی پنهان که از یک بلوک توجه متقابل استفاده می‌کند، ابتدا شرط یا بازنمایی آن را از یک شبکه‌ی تماماً متصل عبور می‌دهند و سپس آن را در قالب پارامترهای تغییر مقیاس^{۳۷} به لایه‌های نرمالسازی لایه‌ای اضافه می‌کند.



شکل ۲-۶: معماری مدل‌های مبتنی بر مبدل

همانطور که شکل نشان می‌دهد، ورودی‌های این مدل تصویر و زمان و برچسب کلاس هستند. تصویر ابتدا قطعه قطعه می‌شود و سپس وارد بلوک مبدل شده و در نهایت نیز یک تبدیل خطی روی آن انجام می‌شود تا با ترکیب قطعات مختلف تصویر نهایی ایجاد شود [۸].

این مدل بر اساس اندازه‌ی قطعه، تعداد سر^{۳۸}های مکانیزم توجه، تعداد لایه‌ها و اندازه‌ی لایه‌ی پنهان می‌تواند انواع گوناگونی داشته باشد. با توجه به آزمایشات انجام شده در مقاله مدل $DIT - XL$ با ۲۸ لایه، اندازه قطعه‌ی ۲، اندازه‌ی لایه‌ی پنهان ۱۱۵۲ و تعداد سرهای ۱۶ بهترین عملکرد را از خود ارائه می‌دهد.

۲-۲ رویکردهای افزایش سرعت

با وجود توسعه‌ی حجم زیادی از مدل‌های مولد در سال‌های اخیر برای انواعی از کاربردها از جمله تصویر، صدا، متن و گراف‌ها، همه‌ی مدل‌های موجود فعلی قابلیت ارضای سه نیاز اصلی یک مدل مولد به کار

^{۳۷}Scale Shift

^{۳۸}Head

گرفته شده در مسائل واقعی را ندارند [۱۵]. این سه نیاز اصلی عبارتند از:

۱. تولید نمونه‌های با کیفیت

۲. پوشش مد و تنوع نمونه‌های تولیدی

۳. نمونه برداری سریع و به صرفه از نظر محاسباتی

به عنوان مثال اکثر مدل‌های تولید تصویر فعلی روی تولید نمونه‌های با کیفیت تمرکز دارند اما تنوع داده‌ها نیز موضوع مهمی در کاهش تاثیرات اجتماعی منفی مدل‌های مولد است. همچنین برای کاربردهای تعاملی نیاز به نمونه برداری سریع یک مساله‌ی حائز اهمیت است. این چالش در ادبیات مدل‌ها مولد به عنوان مشکل سه‌گانه‌ی یادگیری مولد^{۳۹} شناخته می‌شود. هر کدام از مدل‌های مولد در حل بخشی از مشکلات یادگیری مولد تبحر دارند و بخش‌هایی از این سه‌گانه به عنوان ضعف آنها محسوب می‌شود. به عنوان مثال شبکه‌های مولد تقابلی قابلیت تولید نمونه‌های با کیفیت در زمان سریع را دارند اما پوشش مد ضعیفی دارند. از طرفی خودکدگذارهای تغییراتی به خوبی مدهای داده را پوشش می‌دهند و سرعت نمونه‌برداری مناسبی دارند اما کیفیت نمونه‌های تولیدی آنها کم است. برای مقایسه‌ی عملکرد مدل‌های پخشی با سایر مدل‌های مولد خوب است بدانیم که این مدل‌ها قابلیت رفع این مشکل سه‌گانه را دارند یا خیر. مدل‌های پخشی با ظهور خود توانستند از شبکه‌های مولد تقابلی در تولید نمونه‌های با کیفیت پیشی بگیرند و همچنین با تغییر و تنظیم این مدل‌ها و دستیابی به درست‌نمایی بهینه، قابلیت پوشش مدهای مختلف داده را دارند اما نمونه برداری از این مدل‌ها نیازمند ده‌ها بار استفاده از شبکه می‌باشد و همین امر سرعت نمونه برداری را کاهش می‌دهد و به کارگیری آنها در کاربرد را هزینه‌بر و دشوار می‌سازد. شکل ۲-۷ این مشکل سه‌گانه و حوزه‌ی عملکرد مناسب هر مدل را نشان می‌دهد.

با توجه به دسته‌بندی ذکر شده در بند قبل، اصلی‌ترین نقطه ضعف عمده‌ی مدل‌های پخشی سرعت نمونه‌برداری کم آنهاست و در همین راستا حجم زیادی از تحقیقات در سال‌های اخیر به کاهش زمان نمونه‌برداری مدل‌های پخشی اختصاص داده شده است. برای دسته‌بندی این تحقیقات هم رویکردهای متفاوتی وجود دارد. به عنوان مثال می‌توان روش‌ها را بر اساس نیازمندی به آموزش مجدد^{۴۰} و بدون نیاز به آموزش^{۴۱} به دو دسته تقسیم کرد.


روش‌های مبتنی بر آموزش با تغییر قسمتی از مدل یا استفاده از رویکردهای تقطیر دانش^{۴۲} [۲] سعی بر کاهش زمان فرآیند نمونه‌برداری و استفاده از شبکه‌های کوچک‌تر و سریع‌تر برای نویززدایی دارند. مشکل عمده‌ی این روش‌ها این است که برای فرآیند آموزش مجدد نیاز به هزینه‌ی زمانی و پردازشی زیادی دارند و این موضوع با توجه به گسترش ابعاد تصاویر و سنگین‌تر شدن شبکه‌های نویززدا نیز رو به افزایش است. در مقابل روش‌های بدون نیاز به آموزش، از یک شبکه‌ی از پیش آموزش داده‌شده

³⁹Generative learning trilemma

⁴⁰Training-based Methods

⁴¹Training-Free Methods

⁴²Knowledge Distillation



شکل ۲-۷: مشکل سه‌گانه‌ی مدل‌های مولد

سه نیاز اساسی در توسعه‌ی مدل‌های مولد و حوزه‌ی عملکرد موثر هر مدل [۱۵].

^{۴۳} استفاده می‌کنند و سعی می‌کنند تا با تغییر عناصر مختلف موجود در این مدل‌های از پیش آموزش داده شده، زمان نمونه برداری آنها را کاهش دهند.

رویکردهای بهبود سرعت را می‌توان از جنبه‌های دیگری هم دسته‌بندی کرد، یکی از این جنبه‌ها محل اثر رویکرد بهبود سرعت است. اساساً مشکل زمانبر بودن فرآیند نمونه‌برداری در مدل‌های پخشی از دو مساله نشأت می‌گیرد. اول، تعداد گام‌های زیادی که برای نویززدایی نیاز است و دوم، سنگین بودن شبکه‌ی نویزدا که باعث زمانبر بودن محاسبات در هر گام به تنهایی می‌شود. بر همین اساس می‌توانیم رویکردهای افزایش سرعت را به دو دسته‌ی روش‌های کاهش تعداد گام و روش‌های کاهش محاسبات در هر گام تفکیک کنیم. در ادامه مختصراً به هر کدام می‌پردازیم.

۱-۲-۲ رویکردهای کاهش تعداد گام‌ها

رویکردهای موجود در این دسته تلاش می‌کنند تا با کاهش تعداد گام‌ها نویززدایی فرآیند نمونه‌برداری را تسریع کنند. رویکردهای این دسته را مجدد می‌توان به دو دسته‌ی نیازمند یادگیری و بدون نیاز به یادگیری تقسیم کرد. یک دسته‌ی شاخص در این رویکردها روش‌های مبتنی بر تقطیر دانش هستند. روش‌های تقطیر دانش با انتقال دانش از مدل‌های سنگین و نیازمند نمونه‌برداری کامل معلم به مدل‌های سریع‌تر دانش‌آموز تعداد گام مورد نیاز برای فرآیند نمونه‌برداری را کاهش می‌دهند. بر اساس [۷]

⁴³ Pre-trained Network

روش‌های تقطیر دانش نیز به سه دسته‌ی تقطیر دانش مبتنی بر توزیع^{۴۴}، تقطیر دانش مبتنی بر مسیر^{۴۵} و تقطیر دانش تقابلی^{۴۶} تقسیم می‌شوند. نقطه ضعف این مدل‌ها همانطور که در بحث رویکردهای نیازمند آموزش ذکر شد، فرآیند آموزش زمانبر و پرهزینه است و با توجه به اینکه عمدتاً هم شبکه‌ی معلم و هم شبکه‌ی دانش‌آموز بزرگ هستند؛ منابع پردازشی قابل توجهی برای انجام آنها نیاز است. رویکردهای دیگری که در دسته‌ی کاهش تعداد گام قرار می‌گیرند روش‌هایی هستند که با تغییر در قسمتی از فرآیند رو به جلو یا رو به عقب امکان پرش از روی چند گام را فراهم می‌کنند. از جمله‌ی این روش‌ها می‌توان به مدل‌های پخشی نویززدای ضمنی^{۴۷} [۱۳] اشاره کرد. این روش با تغییر فرآیند رو به جلو به یک فرآیند غیر مارکفی، این امکان را فراهم می‌کند که در فرآیند رو به عقب با تعداد گام کمتر و بدون از دست دادن کیفیت، فرآیند نمونه برداری را انجام دهیم. نقطه‌ی قوت اکثر روش‌هایی که در این دسته قرار می‌گیرند این است که بر مبنای یک تئوری ریاضیاتی بنا شده‌اند و در عین حال که انعطاف خوبی برای اعمال روی انواعی از معماری‌ها را دارند؛ می‌توانند به صورت عمود بر روش‌های کاهش محاسبات در هر گام بر مدل پخشی اعمال شوند تا حداکثر کاهش ممکن حاصل شود. از طرفی همانطور که در مثال‌های بالا هم مشاهده شد، عمده‌ی روش‌های شاخص در این دسته مبتنی بر آموزش هستند که نیاز به منابع پردازشی را به عنوان نقطه ضعف با خود دارند.

۲-۲-۲ رویکردهای کاهش محاسبات هر گام

روش‌های کاهش تعداد گام عمدتاً ساختار شبکه‌ی نویز زدا را به صورت یک جعبه سیاه در نظر می‌گیرند. این در حالیست که چه در ساختار شبکه‌ی یو و چه در ساختار مبتنی بر مبدل قسمت‌های متعددی وجود دارند که امکان بهینه‌سازی و بهبود عملکرد دارند. عمده‌ی رویکردهایی که در این قسمت معرفی می‌کنیم بر مبنای تغییر در معماری، فشردگی ساختار شبکه و تکرار محاسبات می‌باشند و هدف تمامی این تغییرات کاهش حجم محاسبات انجام شده در هر گام می‌باشد. رویکردهای کاهش محاسبات را می‌توان بر اساس محل اثر، هدف کلی و نیازمندی به آموزش به دسته‌های مختلفی تقسیم کرد. اما سه رویکرد شاخص، متاخر و عمدتاً بدون نیاز به آموزش در این دسته وجود دارند که بررسی آنها برای درک سازوکار رویکردهای کاهش محاسبات مفید خواهد بود و این دسته‌ها عبارتند از: گسسته‌سازی^{۴۸}، کاهش توکن‌ها^{۴۹} و استفاده از حافظه‌ی پنهان^{۵۰}.

⁴⁴Distribution-based KD

⁴⁵Trajectory-based KD

⁴⁶Adversarial KD

⁴⁷Denosing Diffusion Implicit Models(DDIM)

⁴⁸Quantization

⁴⁹Token Reduction

⁵⁰Caching

۱-۲-۲-۲ گسسته‌سازی

گسسته‌سازی یک تکنیک برای کاهش دقت مقادیر عددی موجود در یک مدل است که معمولاً با تبدیل اعداد ممیز شناور^{۵۱} ۳۲ یا ۱۶ بیتی به بازنمایی‌های کم‌دقت‌تر مانند اعداد صحیح ۸ بیتی انجام می‌شود. رویکردهای گسسته‌سازی به دو دسته‌ی آموزش آگاه از گسسته‌سازی^{۵۲} که در آنها فرآیند گسسته‌سازی همزمان با آموزش انجام می‌گیرد و گسسته‌سازی پس از آموزش^{۵۳} تقسیم می‌شوند.

در مدل‌های پخشی، فرآیند گسسته‌سازی باعث بهبود سرعت نمونه‌برداری و کاهش حجم شبکه‌ی نويززدا می‌شود و با توجه به فرآیند هزینه‌بر آموزش مدل‌های پخشی معمولاً در این مدل‌ها از روش‌های پس از آموزش برای گسسته‌سازی شبکه استفاده می‌شود. و این روش زمان و منابع محاسباتی کمتری نیاز دارد[۱۲]. همچنین با توجه به ماهیت چندگامی بودن مدل‌های پخشی عمده‌ی روش‌های گسسته‌سازی که پیش از این برای شبکه‌های عمیق تک گامی گسترش داده شده بودند، روی این مدل باعث افت کیفیت می‌شوند. از این رو مدل‌هایی مانند گسسته‌سازی پس از آموزش PTQ [۱۲] و گسسته‌سازی مدل پخشی^{۵۴} [۵] ارائه شدند که با تمرکز بر چندگامی بودن مدل‌های پخشی و ماهیت متفاوت داده‌ی دریافت شده در هر گام به گسسته‌سازی شبکه‌ی نويززدا می‌پردازند.

۲-۲-۲-۲ کاهش توکن‌ها

۳-۲-۲-۲ استفاده از حافظه‌ی پنهان

همانطور که پیش‌تر هم اشاره شد روش‌های کاهش گام عمدتاً شبکه‌ی نويززدا را به عنوان یک جعبه‌ی سیاه در نظر می‌گرفتند و بررسی عملکرد بلوک‌های مختلف آن و تاثیر آنها بر سرعت و کیفیت تصویر از جمله مواردی بود که کمتر مورد توجه قرار می‌گرفت. اما ظهور مدل استفاده از حافظه‌ی پنهان عمیق^{۵۵} [۶] باعث ایجاد دسته‌ای از روش‌های استفاده از حافظه‌ی پنهان شد که با بررسی افزونگی^{۵۶} موجود در قسمت‌های مختلف مدل‌های پخشی، این رویکرد را در جهت کاهش حجم محاسبات و کاهش زمان نمونه‌برداری اتخاذ کردند.

در روش استفاده از حافظه پنهان با اتکا به این موضوع که محاسبات در بلوک‌های مختلف و در گام‌های زمانی مختلف دارای افزونگی هستند، قسمتی از محاسبات را در بلوک مربوطه انجام نمی‌شود و این محاسبات را از بلوک قبلی یا گام زمانی قبلی که در حافظه‌ی پنهان ذخیره شده است جایگذاری می‌شود. روش استفاده از حافظه‌ی پنهان بر ویژگی‌های سطح بالای شبکه‌ی یو، کدگشای شبکه‌ی یو، بلوک توجه متقابل و بر تغییرات محاسبه اعمال شده است که در هر یک از مثال‌های زیر یکی از این حالات را ارائه می‌کنیم.

⁵¹Floating-point⁵²Quantization-aware Training⁵³Post-training Quantization⁵⁴Q-diffusion⁵⁵Deep Cache⁵⁶Redundancy