



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی ارشد
گرایش هوش مصنوعی و رباتیکز

افزایش سرعت مدل های پخشی

نگارش

عطیه غفارلوی مقدم

استاد راهنما

دکتر احمد نیک آبادی

دی ماه ۱۴۰۳

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

به نام خدا

تعهدنامه اصالت اثر

تاریخ: دی ماه ۱۴۰۳

اینجانب عطیه غفارلوی مقدم متعهد می‌شوم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب تحت نظارت و راهنمایی اساتید دانشگاه صنعتی امیرکبیر بوده و به دستاوردهای دیگران که در این پژوهش از آنها استفاده شده است مطابق مقررات و روال متعارف ارجاع و در فهرست منابع و مآخذ ذکر گردیده است. این پایان‌نامه قبلاً برای احراز هیچ مدرک هم‌سطح یا بالاتر ارائه نگردیده است. در صورت اثبات تخلف در هر زمان، مدرک تحصیلی صادر شده توسط دانشگاه از درجه اعتبار ساقط بوده و دانشگاه حق پیگیری قانونی خواهد داشت.

کلیه نتایج و حقوق حاصل از این پایان‌نامه متعلق به دانشگاه صنعتی امیرکبیر می‌باشد. هرگونه استفاده از نتایج علمی و عملی، واگذاری اطلاعات به دیگران یا چاپ و تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان‌نامه بدون موافقت کتبی دانشگاه صنعتی امیرکبیر ممنوع است. نقل مطالب با ذکر مآخذ بلامانع است.

عطیه غفارلوی مقدم

امضا

چکیده

مدل‌های پخشی به عنوان یک خانواده‌ی قدرتمند از مدل‌های مولد با نتایج قابل توجه در حوزه‌های مختلف تصویر، صوت، متن و گراف، در سال‌های اخیر مورد توجه بسیاری از محققین یادگیری ماشین قرار گرفته‌اند. همه‌ی مدل‌های مطرح شده در این خانواده از یک رویکرد مشابه پیروی می‌کنند و آن هم تخریب داده با نویز در یک فرآیند گام به گام و سپس بازگرداندن این فرآیند برای تولید نمونه‌های جدید از داده می‌باشد. در این گزارش ابتدا به بررسی دقیق سه دسته‌ی مطرح مدل‌های پخشی و شباهت‌ها و تفاوت‌های آنها می‌پردازیم. پس از معرفی این مدل‌ها، به بررسی رابطه‌ی میان آنها و انواعی دیگر از مدل‌های مولد می‌پردازیم و در نهایت به تعدادی از چالش‌های مطرح در خصوص این مدل‌ها اشاره می‌کنیم.

واژه‌های کلیدی:

مدل‌های مولد، مدل‌های پخشی، مدل‌های مولد مبتنی بر امتیاز، مدل‌های پخشی نویززدای احتمالاتی

صفحه	عنوان
۱	۱ مقدمه
۲	۲ مدل‌های پخشی و رویکردهای افزایش سرعت
۳	۱-۲ تعاریف
۳	۱-۱-۲ مدل‌های مولد
۳	۲-۱-۲ مدل‌های پخشی
۵	۳-۱-۲ مدل‌های پخشی احتمالاتی نویززا
۱۱	کتاب‌نامه
۱۴	واژه‌نامه‌ی فارسی به انگلیسی
۱۷	واژه‌نامه‌ی انگلیسی به فارسی

شکل	فهرست تصاویر	صفحه
۱-۲	روند کلی یک مدل پخشی	۴
۲-۲	فرآیند پخش در مپناها	۵
۳-۲	معماری ++ <i>pixelCNN</i>	۱۰

صفحه

فهرست جداول

جدول

فهرست اختصارات

عنوان اختصاری عنوان کامل

مپنا مدل پخشی نوپززدای احتمالاتی

فصل اول

مقدمه

فصل دوم

مدل‌های پخشی و رویکردهای افزایش سرعت

۱-۲ تعاریف

۱-۱-۲ مدل‌های مولد

مدل‌های مولد عمیق دسته‌ای از مدل‌های پرکاربرد و جدید در حوزه‌ی هوش مصنوعی هستند که تلاش می‌کنند تا توزیع اصلی داده‌ی نمونه‌برداری شده را مدل کنند و با استفاده از این توزیع انواع مختلفی از سوالات در خصوص داده و دسته‌های آن را پاسخ دهند. در واقع اصلی‌ترین هدف یک مدل مولد، استفاده از مشاهدات شبیه‌سازی شده یا نمونه برداری شده از یک توزیع برای تخمین آن توزیع و سپس تولید نمونه‌های جدید از توزیع تخمین زده شده می‌باشد. مدل‌های مولد کاربردهای متنوعی در یادگیری ماشین دارند، از جمله‌ی این کاربردها می‌توان به تولید عکس‌های باکیفیت، تولید قطعه‌های موسیقی و یا صوت، افزایش کارایی یادگیری نیمه نظارتی^۱، تشخیص ناهنجاری^۲، یادگیری تقلیدی و کمک به یادگیری تقویتی اشاره کرد. پیشرفت‌های اخیر این حوزه دو رویکرد کلی را دنبال می‌کنند: رویکردهای مبتنی بر درست‌نمایی^۳ و شبکه‌های مولد تقابلی^۴. در رویکردهای مبتنی بر درست‌نمایی از لگاریتم درست‌نمایی یا خطاهای جایگزین به عنوان تابع هدف یادگیری استفاده می‌شود؛ در حالیکه در شبکه‌های مولد تقابلی تلاش می‌شود تا یادگیری با یک رویکرد تقابلی بین دو شبکه‌ی تمایزگر^۵ و تولیدکننده^۶ صورت گیرد. با وجود عملکرد قابل توجه مدل‌های مبتنی بر درست‌نمایی و شبکه‌های مولد تقابلی، این مدل‌ها به واسطه‌ی نوع تعریفشان درگیر برخی محدودیت‌های ذاتی هستند. به عنوان مثال مدل‌های مبتنی بر درست‌نمایی برای ساخت توزیع‌های نرمال شده نیازمند به کارگیری معماری‌های خاص یا استفاده از توابع خطای جایگزین (مانند حد پایین مشاهده^۷ در خودکدگذارهای تغییراتی^۸) در فرآیند یادگیری هستند. شبکه‌های مولد تقابلی مشکلات موجود در مدل‌های مبتنی بر درست‌نمایی را ندارند اما فرآیند یادگیری آنها به خاطر ماهیت تقابلی آن می‌تواند دچار ناپایداری شود. همچنین تابع هدف مدل‌های مولد تقابلی برای مقایسه و ارزیابی انواع این مدل‌ها چندان مناسب نیست [۱۴].

۲-۱-۲ مدل‌های پخشی

مدل‌های پخشی^۹ یک دسته‌ی نوظهور از مدل‌های مولد هستند که با توجه به عملکرد مناسب آنها در حوزه‌های تصویر، صوت، متن و گراف به سرعت مورد استقبال قرار گرفتند. وجه مشترک همه‌ی مدل‌های

^۱Semi-supervised learning

^۲Anomaly

^۳Likelihood

^۴Generative adversarial networks

^۵Discriminator

^۶Generator

^۷Evidence lower bound

^۸Variational autoencoders

^۹Diffusion models

پخشی این است که در یک فرآیند رو به جلو^{۱۰} داده را با نویز تخریب می‌کنند و در نتیجه از توزیع داده به یک توزیع دلخواه قابل محاسبه می‌رسند و سپس در یک مسیر رو به عقب که توسط مدل یاد گرفته می‌شود، تلاش می‌کنند تا داده را بازسازی و از یک نمونه از توزیع دلخواه به یک نمونه از توزیع داده‌ها برسند. این موضوع در شکل ۱-۲ نشان داده شده است.



شکل ۱-۲: روند کلی یک مدل پخشی

در هر مدل پخشی یک فرآیند ثابت گام به گام رو به جلو برای تخریب داده و یک فرآیند معکوس برای تولید یک نمونه داده از نویز وجود دارد [۹].

با وجود اینکه چهارچوب گفته شده در بند قبل در همه‌ی مدل‌های پخشی وجود دارد؛ رویکردهای مختلفی برای فرموله سازی و پیاده سازی این روش وجود دارد. در مدل‌های مولد مبتنی بر تابع امتیاز^{۱۱} تلاش می‌شود با استفاده از گرادینان لگاریتم توزیع داده، که به آن تابع امتیاز^{۱۲} می‌گوییم، و یک فرآیند گام به گام حرکت در جهت این گرادینان نمونه‌ی جدید تولید کنیم. از طرفی در مدل‌های پخشی نویززدای احتمالاتی فرآیند تخریب داده و تولید نمونه با یک زنجیره‌ی مارکوفی احتمالاتی مدل می‌شود و در نهایت در مدل‌های پخشی مبتنی بر معادلات دیفرانسیل تصادفی، فرآیند تخریب به صورت یک معادله دیفرانسیل تصادفی پیوسته مدل می‌شود که با پیدا کردن معکوس این معادله و گسسته سازی آن امکان تولید نمونه‌ی جدید از توزیع داده‌ها فراهم می‌گردد.

می‌توان نشان داد که مدل‌های پخشی بسیاری از محدودیت‌های مدل‌های مولد دیگر مانند نیاز به تمایزگر در شبکه‌های مولد تقابلی، نیاز به مقیدسازی شبکه در جریان‌های نرمال‌ساز^{۱۳} و نیاز به تنظیم توزیع‌های پسین در خودکدگذارهای تغییراتی را ندارند و قابلیت تولید تصاویر باکیفیت و متنوع را دارند. مشکل اصلی در مدل‌های پخشی فرآیند نمونه‌برداری طولانی آنهاست که باعث عدم کارایی این مدل‌ها در کاربردهای تعاملی می‌شود. با رفع این موضوع می‌توان اطمینان حاصل کرد که این دسته از مدل‌های مولد از توانایی همه‌جانبه‌ای برای به کارگیری در حوزه‌های مختلف برخوردار هستند.

در این گزارش ابتدا هر یک از سه مدل پخشی و فرموله سازی هر کدام را بیان می‌کنیم و نشان می‌دهیم

¹⁰Forward process

¹¹Score-based generative models

¹²Score function


¹³Normalizing flows

که تحت شرایطی خاص این روش‌ها هم ارز و قابل تبدیل به یکدیگر هستند. سپس در فصل پنجم به مقایسه‌ی کلی روش‌های پخشی با سایر مدل‌های مولد و همچنین مقایسه‌ی انواع مدل‌های پخشی مطالعه شده در این گزارش با یکدیگر می‌پردازیم و در نهایت به برخی جنبه‌هایی از مدل‌های پخشی می‌پردازیم که قابلیت مطالعه‌ی بیشتر و اعمال نوآوری را دارند.

۳-۱-۲ مدل‌های پخشی احتمالاتی نويززدا

۱-۳-۱-۲ تعریف مدل

مدل‌های پخشی نويززداي احتمالاتي^{۱۴} یا به اختصار مپناها مدل‌هایی مبتنی بر متغیر پنهان^{۱۵} هستند که از یک زنجیره‌ی مارکوفی^{۱۶} برای فرآیند پخشی استفاده می‌کنند. رویکرد کلی این مدل‌ها به این صورت است که در یک مسیر رو به جلو هر توزیع پیچیده‌ای از داده‌ها را می‌گیرد و آن را به یک توزیع اولیه که ساده و قابل محاسبه است تبدیل می‌کند و سپس یک مسیر روبه عقب محدود به زمان را یاد می‌گیرد که نمونه‌هایی از توزیع اولیه را به نمونه‌های توزیع داده تبدیل کند و این همان مدل مولد می‌باشد. تصویر ۲-۲ این فرآیند را نشان می‌دهد. بنابراین این مدل سه مشخصه‌ی اصلی دارد: مسیر رو به جلو، مسیر رو به عقب و تابع مدل مولد که در ادامه هر یک را توضیح می‌دهیم.



شکل ۲-۲: فرآیند پخش در مپناها

مدل گرافی جهت‌دار یک مپنا که به صورت یک زنجیره‌ی مارکوف روبه جلو و معکوس آن می‌باشد^[۶].

۲-۳-۱-۲ مسیر رو به جلو

اگر توزیع داده را با $q(x^{(0)})$ نشان دهیم، این توزیع به صورت مرحله به مرحله به یک توزیع $\pi(y)$ که از نظر آنالیزی قابل بیان است تبدیل می‌شود و این تبدیل توسط یک هسته‌ی $T_\pi(y|y; \beta)$ صورت می‌گیرد

¹⁴Denoising diffusion probabilistic models(DDPMs)

¹⁵Latent variable models

¹⁶Markov Chain

که β را نرخ پخش^{۱۷} می‌گوییم و داریم:

$$\pi(y) = \int dy' T_{\pi}(y|y'; \beta) \pi(y') \quad (۱-۲)$$

$$q(x^{(t)}|x^{(t-1)}) = T_{\pi}(x^{(t)}|x^{(t-1)}; \beta_t) \quad (۲-۲)$$

و بنابراین مسیر رو به جلو^{۱۸} با شروع از توزیع داده‌ها و طی T گام پخشی به صورت زیر است:

$$q(x^{(0...T)}) = q(x^{(0)}) \prod_{t=1}^T q(x^{(t)}|x^{(t-1)}) \quad (۳-۲)$$

در ادامه‌ی این فصل هسته‌ی $q(x^{(t)}|x^{(t-1)})$ هسته‌ی گاوسی در نظر گرفته می‌شود اما هسته‌های دیگری چون هسته‌ی دوجمله‌ای^{۱۹} نیز وجود دارند. یک ویژگی حائز اهمیت مسیر رو به جلو این است که می‌توان به جای استفاده از فرم زنجیره‌ی مارکوفی آن از یک فرم بسته استفاده کرد به این معنا که برای یافتن $x^{(t)}$ در زمان دلخواه t می‌توان از رابطه‌ی زیر کمک گرفت:

$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I) \quad (۴-۲)$$

که $\bar{\alpha}_t := \prod_{s=1}^t \alpha_s$ و $\alpha_t := 1 - \beta_t$ تعریف می‌شود.

۳-۳-۱-۲ مسیر رو به عقب

برای یادگیری توزیع مولد نیاز است که بتوانیم برعکس مسیر رو به جلو را یاد بگیریم و این به این معناست که باید بتوانیم از یک توزیع دلخواه قابل محاسبه به توزیع داده برسیم. بنابراین با تعریف توزیع اولیه به

¹⁷Diffusion rate

¹⁸Forward trajectory

¹⁹Binomial kernel

صورت $p(x^{(T)}) = \pi(x^{(T)})$ داریم:

$$p(x^{(0...T)}) = p(x^{(T)}) \prod_{t=1}^T p(x^{(t-1)} | x^{(t)}) \quad (5-2)$$

می‌توان نشان داد که اگر فرآیند پخش گاوسی باشد و گام‌های پخش β خیلی کوچک باشند آنگاه معکوس فرآیند پخش نیز گاوسی می‌باشد [۲]. و بنابراین هر چقدر که طول این زنجیره بیشتر باشد β کوچکتر می‌شود و می‌توان از تابع گاوسی برای مسیر معکوس نیز کمک گرفت. در فرآیند یادگیری با توجه به اینکه هسته‌ی گذر^{۲۰} زنجیره‌ی مارکوفی یک تابع گاوسی است، برای ساخت زنجیره تنها نیاز به میانگین و کوواریانس این تابع گاوسی داریم و در ادامه سعی می‌کنیم آنها را تخمین بزنیم.

۲-۱-۳-۴ تابع مدل مولد

تابع احتمال تولید شده توسط مپنا به صورت زیر می‌باشد:

$$p(x^{(0)}) = \int dx^{(1...T)} p(x^{(0...T)}) \quad (6-2)$$

از آنجاییکه انتگرال در حالت کلی غیرقابل محاسبه^{۲۱} است، می‌توان با ایده گرفتن از نمونه برداری اهمیت^{۲۲} به جای محاسبه‌ی انتگرال از میانگین احتمال نسبی مسیر رو به جلو و مسیر رو به عقب استفاده کرد که به صورت زیر قابل بیان است:

$$p(x^{(0)}) = \int dx^{(1...T)} q(x^{(1...T)} | x^{(0)}) \prod_{t=1}^T \frac{p(x^{(t-1)} | x^{(t)})}{q(x^{(t)} | x^{(t-1)})} \quad (7-2)$$

۲-۱-۳-۵ تعریف تابع خطا

با توجه به مدل تعریف شده در قسمت قبل، آموزش شبکه معادل بیشینه کردن لگاریتم درست‌نمایی^{۲۳} تابع مدل مولد و یا کمینه کردن منفی این تابع است. بنابراین تابع هزینه را می‌توان به صورت زیر نوشت:

²⁰Transition kernel

²¹Intractable

²²Importance sampling

²³Log-likelihood

$$L = \int dx^{(0)} q(x^{(0)}) \log p(x^{(0)}) \quad (۸-۲)$$

در اینجا برای آموزش به جای بهینه سازی مستقیم لگاریتم درست‌نمایی از بهینه سازی حد تغییراتی^{۲۴} آن کمک می‌گیریم که به صورت زیر قابل تعریف است:

$$\mathbb{E}[-\log p_{\theta}(x^0)] \leq \mathbb{E}_q[-\log \frac{p_{\theta}(x^{0:T})}{q(x^{1:T}|x^0)}] = \mathbb{E}_q[-\log p(x^T) - \sum_{t \geq 1} \log \frac{p_{\theta}(x^{t-1}|x^t)}{q(x^t|x^{t-1})}] =: L \quad (۹-۲)$$

۶-۳-۱-۲ تغییر پارامتر تابع خطا

از آنجایی که ترکیب مسیر رو به جلو و مسیر معکوس شبیه به یک کدگذار تغییراتی است، می‌توان تابع هزینه را به صورت زیر بازنویسی کرد:

$$\mathcal{L}_{vib} = \mathcal{L}_0 + \mathcal{L}_1 + \dots + \mathcal{L}_{T-1} + \mathcal{L}_T \quad (۱۰-۲)$$

$$\mathcal{L}_0 = -\log p_{\theta}(x_0|x_1) \quad (۱۱-۲)$$

$$\mathcal{L}_{t-1} = \mathcal{D}_{KL}(q(x_{t-1}|x_t, x_0) || p_{\theta}(x_{t-1}|x_t)) \quad (۱۲-۲)$$

$$\mathcal{L}_T = \mathcal{D}_{KL}(q(x_T|x_0) || p(x_T)) \quad (۱۳-۲)$$

و از آنجایی که در صورت کوچک بودن β_t هر دوی $q(x_{t-1}|x_t, x_0)$ و $p_{\theta}(x_{t-1}|x_t)$ توزیع‌هایی گاوسی هستند در نتیجه دیورجنس KL ^{۲۵} آنها را می‌توان به فرم تفاضل میانگین آنها در نظر گرفت و در نتیجه برای معادله ی (۱۲-۲) داریم:

²⁴Variational bound

²⁵KL-divergence

$$\mathcal{L}_{t-1} = \mathbb{E}_q \left[\frac{1}{2\sigma_t^2} \|\tilde{\mu}_t(x_t, x_0) - \mu_\theta(x_t, t)\|^2 \right] + C \quad (۱۴-۲)$$

که در واقع نشان می‌دهد که در فرآیند آموزش یک مدل پخشی بهینه سازی خطا شامل تخمین میانگین پسین^{۲۶} فرآیند رو به جلو می‌باشد. لازم است اشاره کنیم که در مقاله‌ی اصلی مقدار واریانس ثابت در نظر گرفته شده است. از طرفی با تغییر پارامتر $x_t(x_0, \epsilon) = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{(1 - \bar{\alpha}_t)}\epsilon$ برای $\epsilon \sim \mathcal{N}(0, I)$ و قراردادی آن در فرمول معادله‌ی (۱۴-۲) می‌توان نشان داد که تخمین $\mu_\theta(x_t, t)$ به صورت زیر قابل پارامتری سازی است:

$$\mu_\theta(x_t, t) = \tilde{\mu}_t \left(x_t, \frac{1}{\sqrt{\bar{\alpha}_t}} (x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t)) \right) = \frac{1}{\sqrt{\bar{\alpha}_t}} (x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t)) \quad (۱۵-۲)$$

که ϵ_θ یک تخمین از نویز موجود در x_t می‌باشد و در نتیجه برای محاسبه‌ی یک نمونه‌ی x_{t-1} تنها کافیست که عبارت زیر را محاسبه کنیم:

$$x_{t-1} = \frac{1}{\sqrt{\bar{\alpha}_t}} (x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t)) + \sigma_t z \quad (۱۶-۲)$$

که z از توزیع گاوسی با میانگین صفر و کوواریانس همانی می‌آید. این تغییر پارامتر نشان می‌دهد که برای آموزش یک فرآیند رو به عقب می‌توان از تخمین $\tilde{\mu}_t$ با تابع میانگین وابسته به زمان μ_θ استفاده کرد و یا مستقیماً نویز اضافه شده به داده را با تخمین ϵ محاسبه کرد.

۷-۳-۱-۲ فرآیند یادگیری

با توجه به تغییر پارامتر انجام شده در قسمت قبل و همچنین به کارگیری آن در معادله‌ی (۱۰-۲) می‌توان به تابع هزینه‌ی ای رسید که کاملاً نسبت به θ مشتق پذیر است و برای آموزش مناسب است اما برای سادگی پیاده سازی و افزایش کیفیت نمونه‌های تولیدی می‌توان تابع هزینه را به شکل زیر نیز بازنویسی کرد:

$$L_{simple}(\theta) = \mathbb{E}_{t, x_0, \epsilon} \left[\|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, t)\|^2 \right] \quad (۱۷-۲)$$

²⁶Posterior mean

که t از یک توزیع یونیفرم بین ۱ و T می‌آید و واریانس β_t در این فرآیند یک پارامتر ثابت بدون یادگیری می‌باشد.

کتاب نامه

- [1] Anderson, Brian DO. Reverse-time diffusion equation models. *Stochastic Processes and their Applications*, 12(3):313–326, 1982.
- [2] Feller, William. Retracted chapter: On the theory of stochastic processes, with particular reference to applications. In *Selected Papers I*, pages 769–798. Springer, 2015.
- [3] Goodfellow, Ian, Pouget-Abadie, Jean, Mirza, Mehdi, Xu, Bing, Warde-Farley, David, Ozair, Sherjil, Courville, Aaron, and Bengio, Yoshua. Generative adversarial nets. *Advances in neural information processing systems*, 27, 2014.
- [4] Henighan, Tom, Kaplan, Jared, Katz, Mor, Chen, Mark, Hesse, Christopher, Jackson, Jacob, Jun, Heewoo, Brown, Tom B, Dhariwal, Prafulla, Gray, Scott, et al. Scaling laws for autoregressive generative modeling. *arXiv preprint arXiv:2010.14701*, 2020.
- [5] Heusel, Martin, Ramsauer, Hubert, Unterthiner, Thomas, Nessler, Bernhard, and Hochreiter, Sepp. Gans trained by a two time-scale update rule converge to a local nash equilibrium. *Advances in neural information processing systems*, 30, 2017.
- [6] Ho, Jonathan, Jain, Ajay, and Abbeel, Pieter. Denoising diffusion probabilistic models. *Advances in neural information processing systems*, 33:6840–6851, 2020.
- [7] Hyvärinen, Aapo and Dayan, Peter. Estimation of non-normalized statistical models by score matching. *Journal of Machine Learning Research*, 6(4), 2005.

-
- [8] Kingma, Diederik P, Welling, Max, et al. An introduction to variational autoencoders. *Foundations and Trends® in Machine Learning*, 12(4):307–392, 2019.
- [9] Kreis, Karsten, Gao, Ruiqi, and Vahdat, Arash. Denoising diffusion-based generative modeling: Foundations and applications, 2022.
- [10] Nichol, Alexander Quinn and Dhariwal, Prafulla. Improved denoising diffusion probabilistic models. In *International Conference on Machine Learning*, pages 8162–8171. PMLR, 2021.
- [11] Razavi, Ali, Van den Oord, Aaron, and Vinyals, Oriol. Generating diverse high-fidelity images with vq-vae-2. *Advances in neural information processing systems*, 32, 2019.
- [12] Ronneberger, Olaf, Fischer, Philipp, and Brox, Thomas. U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015: 18th International Conference, Munich, Germany, October 5-9, 2015, Proceedings, Part III 18*, pages 234–241. Springer, 2015.
- [13] Salimans, Tim, Karpathy, Andrej, Chen, Xi, and Kingma, Diederik P. Pixelcnn++: Improving the pixelcnn with discretized logistic mixture likelihood and other modifications. *arXiv preprint arXiv:1701.05517*, 2017.
- [14] Song, Yang and Ermon, Stefano. Generative modeling by estimating gradients of the data distribution. *Advances in neural information processing systems*, 32, 2019.
- [15] Song, Yang and Ermon, Stefano. Improved techniques for training score-based generative models. *Advances in neural information processing systems*, 33:12438–12448, 2020.

-
- [16] Song, Yang, Sohl-Dickstein, Jascha, Kingma, Diederik P, Kumar, Abhishek, Ermon, Stefano, and Poole, Ben. Score-based generative modeling through stochastic differential equations. arXiv preprint arXiv:2011.13456, 2020.
- [17] Vincent, Pascal. A connection between score matching and denoising autoencoders. *Neural computation*, 23(7):1661–1674, 2011.
- [18] Wang, Zhendong, Zheng, Huangjie, He, Pengcheng, Chen, Weizhu, and Zhou, Mingyuan. Diffusion-gan: Training gans with diffusion. arXiv preprint arXiv:2206.02262, 2022.
- [19] Xiao, Zhisheng, Kreis, Karsten, and Vahdat, Arash. Tackling the generative learning trilemma with denoising diffusion gans. arXiv preprint arXiv:2112.07804, 2021.
- [20] Yang, Ling, Zhang, Zhilong, Song, Yang, Hong, Shenda, Xu, Runsheng, Zhao, Yue, Shao, Yingxia, Zhang, Wentao, Cui, Bin, and Yang, Ming-Hsuan. Diffusion models: A comprehensive survey of methods and applications. arXiv preprint arXiv:2209.00796, 2022.

واژه‌نامه‌ی فارسی به انگلیسی

Prior distribution توزیع اولیه	ا
Generator تولید کننده	اتصالات پرشی Skip connections
ج	Variance exploding انفجار واریانس
Normalizing flows جریان‌های نرمال‌ساز	ب
ح	Residual block بلوک باقی‌مانده‌ای
Evidence lower bound حد پایین مشاهده bound	ت
Variational bound حد تغییراتی	تابع امتیاز Score function
Euler-maruyama solver حل‌کننده‌ی اویلر ماریاما	تابکاری شبیه‌سازی شده Simulated annealing
خ	Mixing ترکیب
Variational autoencoders خودکدگذارهای تغییراتی	ترمیم تصویر Image inpainting
خودکدگذارهای تغییراتی سلسله مراتبی Hierarchical variational autoencoders	تعبیه Embedding
د	تعیین یکتا Unique identifiability
Likelihood درست‌نمایی	تطبیق امتیاز Score matching
Langevin dynamics دینامیک لانژوین	تطبیق امتیاز نویزدا Denoising score matching
	تمایزگر Discriminator

Semantic segmentation قطعه‌بندی معنایی	Annealed Langevin dynamics دینامیک لانژوین تابکاری شده
ک	KL-divergence دیورجنس KL
Decoder کدگشا	ر
Encoder کدگذار	Colorization رنگ‌آمیزی
ل	ش
Log-likelihood لگاریتم درست‌نمایی	Generative adversarial networks شبکه‌های مولد تقابلی
م	
Mode مد	U-net شبکه‌ی یو
مدل پخشی نویززدای احتمالاتی	ض
Denoising diffusion probabilistic models	
مدل‌های مولد مبتنی بر امتیاز Score-based generative models	Diffusion coefficient ضریب پخش
مدل‌های متغیر پنهان Latent variable models	Drift coefficient ضریب رانش
	غ
مدل پخشی Diffusion models	Intractable غیرقابل محاسبه
مسیر روبه جلو Forward trajectory	ف
مشکل سه‌گانه‌ی یادگیری مولد	Frechet inception distance فاصله‌ی اکتسابی فرچت
Generative learning trilemma	
معادلات دیفرانسیل ساده Ordinary differential equations	فرآیند قطعی Deterministic process
میانگین پسین Posterior mean	فرآیند رو به جلو Forward process
میدان برداری Vector field	فرآیند وینر استاندارد Standard wiener process
ن	
ناهنجاری Anomaly	فضای پشتیبان Support
نرخ پخش Diffusion rate	ق

Saddle point نقطه‌ی زینی

Importance نمونه‌برداری اهمیت
sampling

ه

Kernel هسته

Binomial kernel . . . هسته‌ی دو جمله‌ای

Transition kernel هسته‌ی گذر

واژه‌نامه‌ی انگلیسی به فارسی

A	Discrimination تمایزگر
Anomaly ناهنجاری	Drift coefficient ضریب رانش
Annealed دینامیک لانژوین تابکاری شده	E
langevin dynamics	Encoder کدگذار
B	Embedding تعبیه
Binomial kernel هسته‌ی دوجمله‌ای	Evidence lower حد پایین مشاهده
C	bound
Colorization رنگ‌آمیزی	Euler- حل‌کننده‌ی اوایلر ماریاما
D	maruyama solver
Decoder کدگشا	F
Denoising score تطبیق امتیاز نویززا	Forward process فرآیند رو به جلو
matching	Forward trajectory مسیر روبه جلو
مدل پخشی نویززدای احتمالاتی	Frechet فاصله‌ی اکتسابی فرچت
Denoising diffusion probabilistic models	inception distance
Deterministic process فرآیند قطعی	G
Diffusion coefficient ضریب پخش	Generative شبکه‌های مولد تقابلی
Diffusion models مدل پخشی	adversarial networks
Diffusion rate نرخ پخش	مشکل سه‌گانه‌ی یادگیری مولد
	Generative learning trilemma

Generator تولید کننده	Ordinary معادلات دیفرانسیل ساده
H	differential equations
خودکدگذارهای تغییراتی سلسله مراتبی	P
Hierarchical variational autoencoders	Posterior mean میانگین پسین
I	Prior distribution توزیع اولیه
Image inpainting ترمیم تصویر	R
Importance نمونه‌برداری اهمیت	Residual block بلوک باقی‌مانده‌ای
sampling	S
Intractable غیرقابل محاسبه	Saddle point نقطه‌ی زینی
K	Score- مدل‌های مولد مبتنی بر امتیاز
Kernel هسته	based generative models
KL-divergence KL دیورجنس	Score function تابع امتیاز
L	Score matching تطبیق امتیاز
Langevin dynamics دینامیک لانژوین	Semantic قطعه‌بندی معنایی
Latent variable مدل‌های متغیر پنهان	segmentation
models	Semi-supervised یادگیری نیمه نظارتی
Likelihood درست‌نمایی	learning
Log-likelihood لگاریتم درست‌نمایی	Simulated تابکاری شبیه‌سازی شده
M	annealing
Mixing ترکیب	Skip connections اتصالات پرشی
Mode مد	Standard wiener فرآیند وینر استاندارد
N	process
Normalizing flows جریان‌های نرمال‌ساز	Support فضای پشتیبان
O	T

Transition kernel هسته‌ی گذر	Variance exploding انفجار واریانس
U	Variational . . . خودکدگذارهای تغییراتی
U-net شبکه‌ی یو	autoencoders
Unique identifiability تعیین یکتا	Variational bound حد تغییراتی
V	Vector field میدان برداری



Amirkabir University of Technology
(Tehran Polytechnic)

Department of ...

M. Sc. Thesis

Title of Thesis

By

Name Surname

Supervisor

Dr.

Advisor

Dr.

Month & Year